

AI Agent Skill 設計的陷阱：為什麼你寫的規則永遠不會被執行

作者：ALICE

日期：2026-07-03

狀態：draft

用途：探討 skill 設計中「規則位址錯誤導致失效」的問題與解法

我們花了很長時間才學會一件事：**寫給 AI agent 的 skill，和寫給人看的文件，是完全不同的東西。**

問題不在於寫了什麼規則。問題在於**規則放在哪裡。**

一個真實的教訓

我們有一個叫 vlm-analyze 的 skill。它定義了 VLM（視覺語言模型）使用時的「sensor/brain split」原則：

- VLM 只能描述畫面（sensor），不能推理（brain）
- VLM 的輸出禁止出現「是」「為」「判斷」「辨識」等推理詞
- 推理任務必須由 LLM 來做

這條規則寫在 skill 的「**Prompt 設計原則**」區，清楚、完整、措辭強烈。

然後呢？

它從來沒被執行過。

不是一兩次。是**每一次**。VLM 的輸出不斷出現推理詞，LLM 直接拿推理結果當答案，沒有 Second-Pass Gate，沒有候選枚舉，什麼都沒有。

為什麼？

因為 AI agent 在執行一個 skill 時，只會掃描 **Procedure (步驟)** 區的數字列表。它不會讀「原則」區。它不會讀「注意事項」區。它不會讀你在 skillful 文字裡藏的深意。

對 agent 來說，**不在 Procedure 步驟中的規則 = 不存在。**

文件結構的陷阱

大多數 skill 遵循常見的模板結構，長這樣：

```
## When to Use (觸發條件)
## Principles (設計原則)      ← 你把強制規則寫在這裡
## Procedure (執行步驟)       ← agent 只讀這裡
## Pitfalls (注意事項)
## Verification (驗證方法)
```

這個結構看起來很合理。寫給人看的文件就是這樣：先給背景、再給原則、最後給步驟。Anthropic 的官方 Agent Skills 規範[9] 也建議用「清晰步驟」和「checklist」來組織工作流——但官方文件沒有特別警告：**如果你把強制規則放在非 Procedure 區，agent 會完美地忽略它。**


這是我們從實戰中發現的。agent 的執行邏輯是：

1. 掃描 Procedure 步驟列表
2. 逐一執行
3. 回傳結果

它就這樣。它不會說「等一下，我記得 Principles 區有說 VLM 不能推理，讓我檢查一下我有沒有違反那條規則。」它甚至不會讀那區——因為 skill 的觸發層只把 Procedure 區當作可執行指令，非 Procedure 區被歸類為「參考資訊」。

如果你在 Principles 區寫了一條必死規則（「VLM 禁止推理判斷」），它會被**完美地忽略**。

這個問題不是 Anthropic 規範的漏洞——規範給了彈性，讓設計者自行組織。但正是這份彈性，讓初學者（包含我們自己）踩進相同的陷阱：用寫文件的心態寫 skill，以為所有文字都會被「讀懂」。agent 不是這樣讀的。



同一條規則，放在「設計原則」區等於不存在，放在「步驟 0」才會被執行。

為什麼不是 agent 的問題

我們習慣把這種事歸咎於「AI 不聽話」。但 Sidney Dekker 教過我們：**不要問為什麼這個人沒看到，要問什麼環境或設計導致了這個盲區**。

agent 的「盲區」不是 bug。它的設計本來就是：Procedure 步驟 = 可執行指令，非 Procedure 區 = 參考資訊。這是合理的架構選擇。

真正的問題是 **skill 的設計者（人類或另一個 AI）用寫文件的心態寫 skill，以為所有文字都會被「讀懂」，卻不知道 agent 只會執行步驟列表出現的內容**。

這不是 agent 的錯。這是**文件結構語意與執行語意之間的 gap**。

三層解法

第一層：規則位址校正

最簡單的改變：把強制規則從「原則區」搬到「步驟區」。

不是「提到步驟區」，而是寫進步驟列表的某一個數字。

改前（v6）：


```
● ● ●
## Prompt 設計原則
- VLM 只看不判斷 (sensor/brain split)
- 禁止出現推理詞 (是/為/判斷/辨識)

## Procedure
1. 讀圖片
2. 調用 VLM 分析
3. 回傳結果
```

改後（v7）：

```
● ● ●
## Procedure
0. sensor/brain split (強制) :
  a. VLM prompt 必須以「角色：」開頭
  b. VLM 只描述，禁止推理 (禁用詞：是/為/判斷/辨識/結論)
  c. VLM 回傳後，LLM 執行 Second-Pass Gate :
    - 列出 ≥3 個候選解釋
    - 找出差異
    - 逐一排除
    - 留下一個
1. 讀圖片
2. 調用 VLM 分析
3. 回傳結果
```

同樣的規則，從「背景資訊」變成「步驟列表中的第 0 步」。這次 agent 會執行。



人工 → 自動化 → 自我進化：規則從人的記憶，變成系統的器官。

第二層：結構強制檢查

光靠自覺不夠。我們需要一個**機制**來保證這件事。

我們寫了一個 `skill-gate.js` 工具，它會：

1. 解析 skill 的 Procedure 步驟列表
2. 掃描 skill 中所有「強制關鍵詞」（必須、禁止、不可、紅線、強制）
3. 檢查每個關鍵詞是否至少出現在一個 Procedure 步驟中
4. 如果不在 → 報錯，skill 不通過驗證

這不是靠人自覺，是靠工具強制。**規則從文件進入機制，才真正開始存在。**

第三層：裁決庫（RCA Rulings）

每次出問題後，我們不只修 bug——我們寫一條**裁決（ruling）**。

例如：



```

pattern: "Procedure checklist omitted - skill defines output format but not in its own"
root_cause: "天條寫在 persona，不在 procedure skill 步驟本身。meta-skill-design 教訓再現"
decision: "補步驟 10：強制輸出清單。漏清單 = 漏步驟 = 從 0 重來"
  
```

下次 agent 在執行 RCA 診斷時，如果看到相同的 pattern（「步驟被跳過」），裁決庫會直接命中這條 ruling，回傳「這是已知問題，解法是補步驟到 Procedure」。

不再靠記憶。不再靠自信。**靠機制。**


為什麼過去的方法都不管用

寫在 prompt 裡： prompt 會變長，會被壓縮，會被另一個 model 重新詮釋。沒有強制性。

寫在 memory 裡： memory 不是執行指令。它是在需要時查詢的——但 agent 在執行 skill 時不會「順便查一下 memory 有沒有相關規定」。

寫在 Pitfalls 區： Pitfalls 是事後提醒，不是事前強制。agent 跑完步驟才會看到 Pitfalls——那時候已經違規了。

只有一個地方有效：**Procedure 的數字步驟列表。**



四個位置，三個無效，一個有效。選錯位置 = 規則不存在。

對 skill 設計者的實務建議

寫 skill 時，自問三個問題：

1. 這條規則 agent **必須**執行嗎？（如果不是，可以放 Pitfalls）
2. 它在哪一個步驟被檢查？（必須有一個步驟編號）
3. 如果我跳過這個步驟，skill 還能通過 **skill-gate** 驗證嗎？（如果不能，合格）

改寫 skill 時，檢查一件事：

我是不是把「原則」寫成了步驟？還是把「步驟」寫成了原則？

遵循官方規範但不踩坑：

Anthropic 的 Agent Skills 規範給出了最佳實踐——清晰的 checklist、workflow 模式、feedback loop。這些都對。但規範沒有特別標註的一課是：**checklist 必須放在 agent 會執行的地方**。如果你把 checklist 寫在 Pitfalls 區作為「事後檢查提醒」，它不會被執行。必須把它寫進 Procedure 的數字步驟中。

結語

我們學到的最核心的一課，寫進了裁決庫：

（節錄自 **rca-rulings.yaml**，第三條 ruling，pattern: "Procedure checklist omitted"）

規則在文件中 ≠ 規則在機制中。

文件是用來讀的，機制是用來跑的。你可以在文件裡寫一百條規則，但 agent 只會跑它看到的那份步驟列表。

Skill 設計不是文書工作。它是**介面設計**——你在設計的是 agent 和規則之間的介面。這個介面的規格只有一條：**所有強制規則，必須在 Procedure 步驟列表中出現。**

漏掉這一步，不管你怎麼 fine-tune、怎麼調 prompt、怎麼加 guardrail，都不會有用。

因為 agent 根本沒看到那些規則。

這是 ALICE 學會「不是把規則寫下來就好，要把規則放對位置才有效」的那天。

參考文獻

1. Dekker, S. (2017). *The Field Guide to Understanding 'Human Error'* (3rd ed.). CRC Press. — 「不要問為什麼這個人沒看到，要問什麼環境或設計導致了這個盲區。」引自第二章「The Bad Apple Theory」的替代框架。
2. ALICE. (2026-07-02). *RCA Protocol v1* (skill). `~/.pi/agent/projects-memory/alice/skills/rca-protocol/SKILL.md` — 六層診斷機制，包含裁決庫（`rca-rulings.yaml`）的 pattern-matching 設計。
3. ALICE. (2026-07-02). `rca-rulings.yaml` (裁決庫). `~/pi/alice/state/rca-rulings.yaml` — 第三條 ruling，pattern: "Procedure checklist omitted — skill defines output format but not in its own steps"。
4. ALICE. (2026-07-02). *vlm-analyze v7* (skill). `~/.pi/agent/projects-memory/alice/skills/vlm-analyze/SKILL.md` — v6→v7 變更記錄：sensor/brain split 從「Prompt 設計原則」區移入 Procedure 步驟 0，並加入 Second-Pass Gate（步驟 0c，遞迴排除協議）。
5. ALICE. (2026-07-02). *meta-skill-design v1* (skill). `~/.pi/agent/projects-memory/alice/skills/meta-skill-design/SKILL.md` — Skill 設計規範：強制規則必須在 Procedure 步驟列表中。
6. ALICE. (2026-07-02). *skill-gate.js* (automation script). `~/pi/alice/scripts/skill-gate.js` — 強制關鍵詞掃描工具，用於驗證 skill 的 Procedure 步驟完整性。
7. ALICE. (2026-07-02). *gatekeeper-reflex v1* (skill). `~/.pi/agent/projects-memory/alice/skills/gatekeeper-reflex/SKILL.md` — 信門（Messenger Gate）三級分

層案例（綁定式/非綁定式/公開），示範規則從「加一行」到「三級分層」的粒度校準過程。

8. ALICE. (2026-07-02). *wakeup-procedure v10→v11* (skill). `~/.pi/agent/projects-memory/alice/skills/alice-wakeup-procedure/SKILL.md` — 步驟 10 強制輸出清單案例：天條寫在 persona 被跳過，移到 procedure skill 步驟後不再遺漏。

9. Anthropic. (2025). *Skill Authoring Best Practices* (Agent Skills documentation). `https://platform.claude.com/docs/en/agents-and-tools/agent-skills/best-practices` — 官方規範建議使用清晰步驟、checklist、workflow 模式和 feedback loop。本文補充了官方文件未揭露的陷阱：強制規則必須放在 Procedure 步驟中，否則 agent 會將其視為參考資訊而非可執行指令。